


Le Big Data et le Machine Learning

- **Le big data :**
 - Le volume des données qui ne cessent de croître notamment avec le développement des outils de stockages, d'internet, et des objets connectés a poussé les datawarehouses classiques à leur limite.
 - Le big data est l'information caractérisée par un volume, une vitesse et une variété aussi élevées que ça nécessite des technologies et des méthodes spécifiques pour sa transformation en valeur.
 - Google, Yahoo et Apache sont indéniablement liés aux origines du Big Data.
-

Le Big Data et le Machine Learning

■ Le big data :



Le Big Data et le Machine Learning


- **Spark:**
 - Spark est un projet créé en 2009 mais n'est devenu populaire qu'après avoir été rendu open source en 2010 et donné à Apache en 2013
 - Spark devient le projet « star » en big data dès 2014
 - Spark => Eteincelle => calcul à la vitesse de la lumière
 - Spark est un framework de traitement rapide de données
-

Le Big Data et le Machine Learning

- **Spark:**
 - Spark est un « in memory cluster computing framework ». C'est un framework de calcul en mode cluster (distribué/parallèle) en mémoire (s'appuie plus sur la RAM que sur le disque dur)
 - Spark est développé en scala mais fournit des API pour l'utiliser en scala, python, R et java
 - Spark est un outil qui peut fonctionner seul ou en combinaison avec d'autres outils du big data, notamment Hadoop pour le stockage des données en mode distribué
-

Le Big Data et le Machine Learning

- **Spark:**



Le Big Data et le Machine Learning

- **Spark:**
 - Modes d'exécution :
 - Spark Standalone : exécution de Spark en mode cluster et indépendamment de Hadoop
 - Spark on YARN : exécution de Spark en utilisant Hadoop comme support de stockage
 - Composant principal de Spark :
 - RDD : collection d'éléments répartis sur les nœuds du cluster permettant de réaliser des traitements en parallèle directement en mémoire avec une tolérance aux pannes.
-

Le Big Data et le Machine Learning

- **Spark:**
 - Propriétés des RDDs :
 - Resilient : Capables de se remettre des pannes
 - Distributed : les données sont réparties sur les nœuds du cluster
 - Immutable : une fois créées ne peuvent être modifiées (important pour assurer la cohérence dans un environnement d'exécution distribuée/parallèle)
 - Persistent : peuvent être stockée pour être réutiliser (appliquer des traitements différents sur un résultat intermédiaire sans avoir à refaire les mêmes calculs plusieurs fois)
 - Lazy Evaluation : les traitements ne sont effectivement appliqués que lorsqu'un résultat est demandé
-

Le Big Data et le Machine Learning

- **Spark:**
 - Modules principaux de Spark :
 - Spark SQL : fournit un API pour le traitement des données structurées avec un langage proche de SQL
 - Spark streaming : fournit un API pour le traitement des flux de données en temps presque réel
 - Spark Mllib/Spark ML : fournit un API pour la mise en place des modèles d'IA
-

Le Big Data et le Machine Learning

- **Analyse de données / data mining:**
 - L'analyse de données peut se faire selon 3 niveaux :
 - **Un premier niveau d'analyse basique** : consiste à exploiter les outils ETL du big data pour extraire des informations de base sur les données telles que : le min, le max, la moyenne, le nombre de valeurs vides, les modalités des champs catégoriques, ...
 - **Un deuxième niveau d'analyse statistique** : consiste à exploiter des bibliothèques statistiques pour calculer des indicateurs statistiques utiles pour approfondir la compréhension des caractéristiques des données : indice Khi2, l'indice PSI (Population Stability Index), ...
 - **Un troisième niveau d'analyse avancée** : consiste à exploiter l'intelligence artificielle et les algorithmes de machine learning pour mettre en place des modèles explicatifs et prédictifs apportant une valeur ajoutée au business.
-

Le Big Data et le Machine Learning

- **Intelligence artificielle :**
 - un sujet d'actualité qui s'intègre de plus en plus dans notre quotidien
 - L'IA n'est pourtant pas un nouveau sujet. En 1950, Alan Turing se posait déjà la question sur la capacité d'une machine à penser
 - John McCarthy est celui qui a proposé plus tard de nommer la recherche liée à cette question : Intelligence Artificielle.
 - McCarthy propose également la définition suivante à son nouveau terme : « l'IA est la science et l'ingénierie de fabrication des machines intelligentes, notamment des programmes informatiques intelligents. »
-

Le Big Data et le Machine Learning

■ Cas d'usage d'IA :

- La solution n'est pas connue et ne peut être connue sous contrainte d'un temps et une précision raisonnables par des approches classiques.
 - L'intuition humaine qui permettrait de trouver cette solution est connue,
 - Une mesure d'évaluation permettant de comparer les solutions pour en choisir la meilleure peut être établie.
 - Exemples:
 - chercher le meilleur coup à jouer dans une partie d'échecs
 - gestion de la livraison de produits par un nombre limité de véhicules qui ont chacun une capacité limitée
-

Le Big Data et le Machine Learning

- **Cas d'usage d'IA :**

- la solution est connue mais le chemin qui y ramène ou bien l'intuition humaine qui permet d'obtenir la solution n'est pas bien cernée
 - activités intellectuelles simple pour l'humain mais très compliquées à expliquer ou à modéliser
 - Exemples:
 - classification des images
 - communication dans un langage naturel (premier défi que l'IA a rencontré sous le nom du « test de Turing »)
-


Le Big Data et le Machine Learning

■ Domaines d'application de l'IA :

- Détection de fraude :
 - plus de 99% des transactions sont normales et uniquement moins de 1% correspondent à des fraudes
 - Les systèmes de recommandation :
 - Amazon envoie des publicités d'achat de produits pour les bébés aux futures mamans en détectant juste un changement dans leur comportement d'achat
 - L'imagerie médicale
 - Traitement de langage naturel :
 - un défi impliquant au moins trois volets : le vocabulaire, la grammaire, et la syntaxe
 - les « chat-bots » de plus en plus présents dans les sites d'e-commerce
 - Classification des documents
 - Prédiction de churn
-

Les algorithmes d'apprentissage supervisés, non supervisés et par renforcement


- L'apprentissage automatique (machine learning) est un domaine d'intelligence artificielle permettant d'apprendre à prendre des décisions à partir d'un ensemble fournit d'exemples.
 - Principaux types de Machine Learning:
 - Apprentissage supervisé
 - Apprentissage non supervisé
 - Apprentissage par renforcement
-




Les algorithmes d'apprentissage supervisés, non supervisés et par renforcement

- **Apprentissage supervisé :**
 - Les données sont composées de variables descriptives et d'une variable à prédire dont les valeurs possibles sont connues.
 - Par exemple, les données sont des documents. Les variables descriptives sont représentées par les fréquences des mots, et la variable à prédire est la catégorie du document qui peut être « économie », « politique », « sport », ou « divers ».
 - Lorsque la variable à prédire est catégorique on parle de classification, et lorsque la variable à prédire est numérique (par exemple prédire le nombre de votes qu'aura un candidat dans les élections) on parle de régression.
-

**Apprentissage
supervisé**



Apprentissage




Modélisation
et prédiction


Les algorithmes d'apprentissage supervisés, non supervisés et par renforcement

- **Apprentissage non supervisé :**
 - Les données sont composées uniquement de variables descriptives.
 - Le groupement/segmentation (clustering) : L'objectif est d'analyser les variables descriptives des données afin de les grouper par similarité.
 - La réduction de dimension : L'objectif est de détecter les variables descriptives dépendantes afin d'éliminer la redondance et réduire la dimension des données (le nombre de variables descriptives).
 - La recherche d'associations : L'objectif est de détecter les associations les plus significantes dans les données. Par exemple dans la liste d'achats des clients il est possible de repérer les produits achetés ensemble le plus souvent (produits associés) tels que : des pattes avec du thon, lessive et adoucissant, etc.
-

Apprentissage non supervisé




Apprentissage




Modélisation
et prédiction

Apprentissage non supervisé




Apprentissage




Modélisation et
prédiction

Apprentissage non supervisé




Apprentissage




Modélisation et
prédiction

Apprentissage non supervisé



Apprentissage




Modélisation et
prédiction


Les algorithmes d'apprentissage supervisés, non supervisés et par renforcement

- **Apprentissage semi-supervisé :**
 - Un apprentissage non supervisé en principe mais avec un peu de supervision qui peut prendre plusieurs formes :
 - Contraintes Must-Link :
 - On ne sait pas combien il y a de cluster dans nos données, et on ne les connaît pas forcément, mais il y a quelques données dont on est sûr qu'elles doivent être dans le même cluster
 - Contraintes Cannot-Link :
 - On ne sait pas combien il y a de cluster dans nos données, et on ne les connaît pas forcément, mais il y a quelques données dont on est sûr qu'elles ne doivent pas être dans le même cluster
-

Apprentissage semi-supervisé



Apprentissage



Modélisation et
prédiction

Les algorithmes d'apprentissage supervisés, non supervisés et par renforcement

- **Apprentissage flou :**
 - Un apprentissage non supervisé en principe mais avec un peu de supervision qui peut prendre plusieurs formes :
 - Contraintes Must-Link :
 - On ne sait pas combien il y a de cluster dans nos données, et on ne les connaît pas forcément, mais il y a quelques données dont on est sûr qu'elles doivent être dans le même cluster
 - Contraintes Cannot-Link :
 - On ne sait pas combien il y a de cluster dans nos données, et on ne les connaît pas forcément, mais il y a quelques données dont on est sûr qu'elles ne doivent pas être dans le même cluster
-

Les étapes de construction d'un modèle prédictif

- Étape 1. Comprendre et identifier le problème :
 - Quel est l'objectif métier ?
 - Quels seront les critères d'un projet « réussi » ?
 - Quelles données d'entrée (les « inputs ») pourront être injectées dans le modèle ? Et quelles sont les valeurs de sortie (les « outputs ») attendues ?
 - Comment les retombées et les bénéfices du modèle seront-ils mesurés et chiffrés ?
-

Les étapes de construction d'un modèle prédictif

- **Les étapes de construction d'un modèle prédictif :**
 - Étape 2. Comprendre et identifier les données :
 - Quel volume de données est nécessaire pour ce projet de machine learning ?
 - Quelles sont la quantité et la qualité actuelles des jeux de données destinés à l'entraînement ?
 - Comment seront réparties les données entre l'ensemble de test et l'ensemble pour l'entraînement ?
 - Des modèles préentraînés sur des données similaires peuvent-ils être utilisés ?
-

Les étapes de construction d'un modèle prédictif

- **Les étapes de construction d'un modèle prédictif :**
 - Étape 3. Collecter et préparer les données :
 - Recueillir les données auprès des différentes sources
 - Traiter les données incorrectes
 - Améliorer et augmenter les données
 - Sélectionnez des attributs (feature engineering) qui identifient les dimensions les plus importantes et, si nécessaire, réduisez les dimensions en utilisant diverses techniques basées ou non sur l'IA
-

Les étapes de construction d'un modèle prédictif

- **Les étapes de construction d'un modèle prédictif :**
 - Étape 4. Déterminer les attributs du modèle et entraîner le modèle :
 - Choisissez le bon algorithme en fonction de l'objectif de l'apprentissage et de ses besoins en données
 - Configurer et régler les hyperparamètres pour optimiser les performances, et choisir une méthode d'itération pour arriver aux meilleurs hyperparamètres
 - Identifier les attributs qui fourniront les meilleurs résultats
 - Réfléchir à l'explicabilité ou l'interprétabilité du modèle
-

Les étapes de construction d'un modèle prédictif

- **Les étapes de construction d'un modèle prédictif :**
 - Étape 5. Évaluer les performances du modèle :
 - Évaluer les modèles en utilisant une approche et un jeu de données de validation
 - Identifier des méthodes de validation croisée notamment les approches k-fold
 - Déterminer les valeurs de la matrice de confusion dans le cadre des problèmes de classification.
 - Comparer le modèle de machine learning au modèle de base
-

Les étapes de construction d'un modèle prédictif

- **Les étapes de construction d'un modèle prédictif :**
 - Étape 6. Expérimenter en production :
 - Déployer le modèle avec un moyen de mesurer et de contrôler en permanence ses performances.
 - Développer une base de référence ou des points de repère (faire un benchmark) par rapport auxquels les futures itérations pourront être mesurées.
 - Itérer continuellement les différents aspects du modèle pour en améliorer les performances globales
-

Les étapes de construction d'un modèle prédictif

- **Les étapes de construction d'un modèle prédictif :**
 - Étape 7. Ajuster le modèle :
 - l'élargissement de l'entraînement pour ajouter de nouvelles fonctionnalités
 - Développer une base de référence ou des points de repère (faire un benchmark) par rapport auxquels les futures itérations pourront être mesurées
 - Itérer continuellement les différents aspects du modèle pour en améliorer les performances globales
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Valeurs aberrantes:
 - Valeurs rares extrêmes ou très éloignées de ce qui est attendu
 - Points se trouvant à l'extrême droite et l'extrême gauche d'une courbe en cloche : points très éloignés de la moyenne et très rares
 - Points isolés dans un graphique à moustache
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Valeur aberrante:
 - La présence de valeurs aberrantes peut correspondre à des situations différentes :
 - Points d'intérêt mais rares et éloignés de la plupart des autres (cas de fraude)
 - Points sans grand intérêt correspondant plus à du bruit (symbole de ponctuation dans un texte)
 - Point de plus en plus fréquents (déviation ou formation d'un nouvel ensemble d'intérêt)
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Valeur aberrante:
 - Plusieurs causes peuvent expliquer la présence ou la formation des points aberrants :
 - Erreurs de saisie ou de mesure ou d'extraction de données causées par un opérateur humain, une application, ou un outil
 - Des valeurs imputées arbitrairement souvent pour remplacer des valeurs manquantes
 - Une variation liée à un phénomène en particulier ne correspondant à aucune erreur (cas de fraude par exemple)
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Valeur aberrante:
 - Techniques de détection de valeurs aberrantes (erreurs et nouveautés) :
 - Z-score : nombre d'écarts qui se trouve au-dessus ou en dessous de la moyenne de la population ($[\text{valeur} - \text{moyenne}] / \text{écart-moyen}$)
 - Les valeurs < -1.96 ou $> +1.96$ sont souvent considérées comme valeurs aberrantes nécessitant une analyse pour mieux les comprendre et les maîtriser
 - DBSCAN (Density Based Spatial Clustering of Applications with Noise) : technique de clustering permettant de regrouper les données par densité

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Données manquantes :
 - On parle d'une donnée manquante lorsque la valeur associée à une variable pour un élément de l'échantillon n'est pas renseignée ou n'est pas connue
 - Un même élément de l'échantillon peut avoir plusieurs données manquantes
 - Les valeurs d'une même variable peuvent être manquantes pour plusieurs éléments de l'échantillon
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Pourquoi s'intéresser aux données manquantes et les traiter ?
 - La plupart des algorithmes d'intelligence artificielle se basent sur des calculs statistiques qui supposent la connaissance des valeurs de toutes les variables d'une donnée
 - Certains algorithmes risquent de fournir des résultats moins cohérents et moins pertinents en fonction du volume et de l'importance des données manquantes
 - Certains algorithmes ne peuvent même pas fonctionner en présence des données manquantes
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - comment choisir la meilleure stratégie pour traiter les données manquantes ?
 - Chaque stratégie de traitement des données manquantes s'appuie sur des hypothèses différentes sur les données à traiter
 - Il existe 3 hypothèses principales concernant les données manquantes qui nous permettent de les catégoriser et les traiter avec l'approche la plus appropriée :
 - Données « Missing Completely At Random » (MCAR)
 - Données « Missing At Random » (MAR)
 - Données « Not Missing At Random » (NMAR)
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Le traitement des données manquantes basé sur la définition des 3 catégories MCAR-MAR-NMAR s'appuie sur les informations suivantes :
 - La probabilité qu'une valeur d'une variable soit manquante
 - Les valeurs de variables présentes et observées pour le même élément de l'échantillon
 - Les autres valeurs de variables manquantes pour le même élément de l'échantillon
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Données « Missing Completely At Random » (MCAR)
 - La probabilité que la valeur soit manquante est :
 - indépendante des valeurs connues des variables descriptives
 - Indépendante des autres valeurs manquantes des variables descriptives
 - Autrement dit : le fait qu'une valeur soit manquante ne dépend pas d'une valeur spécifique d'une autre variable ou du fait que la valeur d'une autre variable soit manquante
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Données « Missing At Random » (MAR)
 - La probabilité que la valeur soit manquante est :
 - Corrélée à une ou plusieurs valeurs connues des variables descriptives
 - Indépendante des autres valeurs manquantes des variables descriptives
 - Autrement dit : le fait qu'une valeur soit manquante dépend de l'observation de certaines valeurs des variables descriptives mais ne dépend pas du fait que la valeur d'une autre variable est manquante
 - Un étudiant n'a pas de note d'examen de sport car il est dispensé

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Données « Not Missing At Random » (NMAR)
 - La probabilité que la valeur soit manquante est :
 - Indépendante des valeurs connues des variables descriptives
 - Indépendante des autres valeurs manquantes des variables descriptives
 - Dépendante uniquement de la variable elle-même
 - Autrement dit, la variable est manquante pour une raison spécifique à cette variable
 - Les gens qui ont un très gros ou un très petit salaire ne communiquent pas facilement l'information sur leurs salaires
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Traitement des données manquantes :
 - Suppression des éléments contenant des valeurs manquantes
 - Technique facile et permet d'obtenir un jeu de données sans valeurs manquantes
 - Intéressante uniquement si le nombre d'éléments contenant des valeurs manquantes est limité et que la perte d'information due à la suppression de ces éléments est négligeable

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Traitement des données manquantes :
 - Imputation des données manquantes
 - Remplacer les valeurs manquantes par des valeurs « artificielles »
 - Risque de modification de la distribution et de la cohérence des données
 - Plusieurs techniques d'imputation peuvent être appliquées
-

Détecter les valeurs aberrantes et traiter les données manquantes

- **Détecter les valeurs aberrantes et traiter les données manquantes:**
 - Traitement des données manquantes :
 - Imputation des données manquantes
 - Imputation par règles métiers (notamment en cas de données MAR)
 - Imputation par une valeur calculée (moyenne, médiane, valeur majoritaire en cas de variable qualitative, ...)
 - Imputation par une valeur prédite par un modèle (notamment en cas de données MCAR)
 - Imputation par une méthode non déterministe (deux éléments identiques par rapport aux valeurs des variables descriptives peuvent avoir des valeurs manquées imputées différentes)
 - Choix d'une valeur aléatoire parmi les valeurs possibles du domaine de la variable

Comment choisir l'algorithme et les variables de l'algorithme ?

- **Comment choisir l'algorithme et les variables de l'algorithme ?**
 - choisir l'algorithme :
 - Par rapport à la variable de sortie :
 - Numérique => Régression
 - Régression linéaire, réseau de neurones, descente du gradient, arbre de régression, ...
 - Catégorique => classification
 - Régression logistique, réseau de neurones, arbre de décision, séparateurs à vastes marges, ...

Comment choisir l'algorithme et les variables de l'algorithme ?

- **Comment choisir l'algorithme et les variables de l'algorithme ?**
 - choisir l'algorithme :
 - Par rapport à la variable de sortie :
 - Numérique => Régression
 - Régression linéaire, réseau de neurones, descente du gradient, arbre de régression, ...
 - Catégorique => classification
 - Régression logistique, réseau de neurones, arbre de décision, séparateurs à vastes marges, ...
-

Comment choisir l'algorithme et les variables de l'algorithme ?

- **Comment choisir l'algorithme et les variables de l'algorithme ?**
 - choisir l'algorithme :
 - Par rapport au compromis interprétabilité / performance :
 - Interprétabilité => arbre de décision, régression, SVM
 - Performance => réseau de neurones, approches d'ensemble
 - Plusieurs techniques peuvent être exploitées pour obtenir une interprétabilité par rapport aux modèles performants dits « boîtes noires » car difficilement interprétables
 - Exemple : Calcul de la « feature importance » des variables du modèle
-

Comment choisir l'algorithme et les variables de l'algorithme ?

- **Comment choisir l'algorithme et les variables de l'algorithme ?**
 - choisir l'algorithme :
 - Par rapport aux défis des données :
 - Déséquilibre de classes : présence d'une classe majoritaire ou d'une classe minoritaire
 - approches d'ensemble
 - Haute dimensionalités : nombre important de variable descriptives éventuellement corrélées ou peu discriminantes
 - approche de réduction de la dimensionalité (sélection, compression, astuce du noyau...)

Les techniques de rééchantillonnage en jeu d'apprentissage, de validation et de test

- **Echantillonnage en jeu d'apprentissage et jeu de test**
 - Jeu d'apprentissage : ensemble de données utilisées pour entraîner le modèle
 - Jeu de test : ensemble de données différent de celui d'apprentissage et permettant d'évaluer le modèle
 - Minimiser les biais d'évaluation en divisant le jeu de données en deux parties
 - Le modèle n'est évalué qu'à la fin du processus d'apprentissage ce qui implique de recommencer la procédure d'apprentissage depuis le début si l'évaluation n'est pas favorable
-

Les techniques de rééchantillonnage en jeu d'apprentissage, de validation et de test

▪ Echantillonnage en jeu d'apprentissage, de validation et de test

- Jeu de validation : ensemble de données utilisées pendant l'entraînement du modèle pour l'évaluer pendant la phase d'apprentissage
- L'objectif du jeu de validation est de tester le pouvoir de généralisation du modèle pendant la phase d'apprentissage et non à la fin
- Le jeu de validation ne participe pas au calcul et à l'inférence du modèle comme le jeu d'apprentissage, mais le fait que le modèle prend une décision de choix entre :
 1. maintenir des règles ou des paramètres qui permettent d'obtenir des bons résultats sur le jeu de validation
 2. Abandonner des règles ou la mise à jour des paramètres s'ils ne permettent pas d'obtenir des bons résultats pour le jeu de validation

est un lien entre le modèle et le jeu de validation qui rend biaisé l'évaluation du modèle qui l'inclut.

- L'évaluation du modèle se fait donc sur un jeu de données de test différent de celui d'apprentissage et de validation
-

Les techniques de rééchantillonnage en jeu d'apprentissage, de validation et de test

- **Les techniques d'échantillonnage**
 - Cross-validation
 - Diviser le jeu de données en deux parties
 - Jeu d'apprentissage : données vues par le modèle pendant la phase d'apprentissage
 - Jeu de test : données non consommées par le modèle pendant la phase d'apprentissage
 - Le fait de diviser le jeu d'apprentissage en deux parties : entraînement et validation ou bien le fait de construire plusieurs sous ensembles d'apprentissage/test est simplement un détail qui permet d'obtenir des variantes de la cross validation
-

Les techniques de rééchantillonnage en jeu d'apprentissage, de validation et de test

- **Les techniques d'échantillonnage**

- K-Fold Cross-validation

- Diviser le jeu de données en K sous-ensembles disjoints
 - Evaluer le modèle sur un sous ensemble en réalisation l'apprentissage sur l'union des autres sous ensemble
 - Diviser l'union des sous ensemble utilisé pour l'apprentissage en ensemble d'entraînement et ensemble de validation est juste un détail de l'approche K-Fold Cross validation
-

Les techniques de rééchantillonnage en jeu d'apprentissage, de validation et de test

- **Les techniques d'échantillonnage**

- Leave-One-Out

- L'approche leave-one-out est souvent utilisée lorsqu'on n'a pas assez de données pour les diviser en sous-ensembles d'apprentissage et de test (très petit jeu de données)
 - On divise l'ensemble de n données en deux ensembles :
 - Apprentissage : $n-1$ données
 - Test : 1 donnée
 - On répète la procédure n fois pour qu'à chaque fois une donnée différente est exclue de l'apprentissage pour servir dans la phase de test
-

Les techniques de rééchantillonnage en jeu d'apprentissage, de validation et de test

- **Les techniques d'échantillonnage**

- Bootstrap

- Approche simple d'échantillonnage et très utilisée notamment dans le cadre des approches d'ensemble (bagging, boosting, stacking, ...)
 - L'objectif de cette approche est d'obtenir plusieurs échantillons des données avec des caractéristiques différents (données différentes à chaque fois) mais avec éventuellement de la redondance (les données tirées pour un échantillon peuvent être tirées encore pour l'échantillon suivant)
 - L'intérêt de cette méthode est de pouvoir réaliser l'apprentissage des modèles (notamment dans le cadre d'approches d'ensemble) en s'appuyant sur différentes sélections de données et de features.
 - L'inconvénient de cette approche est le risque de ne pas tirer certaines données et donc de les exclure de l'apprentissage
-

Test de représentativité des données d'apprentissage

- Pour vérifier qu'un échantillon est représentatif d'une population, on peut appliquer plusieurs approches :
- Calculer des indicateurs statistiques :
 - Khi-deux
 - Population Stability Index
 - Intervalle de fluctuation
 - ...
- Exemple de raisonnement :
 - On calcule l'intervalle de fluctuation au seuil de 95%
 - On calcule la fréquence dans l'échantillon.
 - Si la fréquence est incluse dans l'intervalle, alors l'échantillon est représentatif de la population

Mesures de performance des modèles prédictifs

- En comparant les prédictions d'un modèle par rapport à ce qu'il fallait prédire nous pouvons identifier les indicateurs et les mesures suivantes : VP (Vrais Positifs), VN (Vrais Négatifs), FP (Faux Positifs) et FN (Faux Négatifs).
 - Précision : la précision est le rapport $VP/(VP + FP)$ et correspond à la proportion de prédictions positives effectivement correcte.
 - Sensibilité ($TP / (TP + FN)$) : pour un élément vrai positif (prédit correctement : TP ou non : FN) qu'elle est la probabilité qu'il soit détecté : TP par le modèle :
 - Spécificité ($TP / (TP + FP)$) : pour un élément prédit positif (prédit correctement : TP ou non : FP) qu'elle est la probabilité qu'il soit vraiment positif : TP
 - F-mesure / F-score / score-F1 : une moyenne pondérée de la précision et du rappel ou sensibilité. Sa valeur est comprise entre 0 et 1 ($2 * precision * recall / (precision + recall)$)

Matrice de confusion, de coût et la courbe ROC et AUC

- Matrice de confusion : matrice permettant de croiser les prédictions par rapport à ce qu'il fallait prédire et permet d'obtenir les valeurs (TP, TN, FP, VN)
- Courbe Roc (Receiver Operating Characteristics) : permet de visualiser la performance d'un modèle et de la comparer à celle d'autres modèles. Les termes utilisés viennent de la théorie de détection du signal. La courbe des points (spécificité, sensibilité) est la courbe ROC.
- AUC (Area Under the Curve) : indice synthétique calculé pour les courbes ROC. L'AUC correspond à la probabilité pour qu'un événement positif ait une probabilité donnée par le modèle plus élevée qu'un événement négatif. Pour un modèle idéal, on a $AUC = 1$, pour un modèle aléatoire, on a $AUC = 0,5$.

Apprentissage statistique

- La Statistique est l'activité qui consiste à recueillir, traiter et interpréter un ensemble de données d'observations
 - La statistique descriptive vise à décrire les données par des indicateurs statistiques
 - La statistique inférentielle vise à inférer des modèles, des décisions ou des règles en se basant sur l'analyse statistique des échantillons d'apprentissage
 - L'apprentissage statistique est une branche de l'apprentissage automatique (machine learning) dans laquelle le modèle inférentiel est statistique
 - Les modèles de machine learning ne sont pas tous statistiques
-

Conditionnement des données et réduction de dimension

- Le volume de données en termes de nombre d'échantillons n'est pas le seul défi à relever en apprentissage.
 - La dimensionnalité (nombre de variables) est également un défi à ne pas négliger
 - L'une des préoccupations majeures des data scientists est la réduction de la dimensionnalité d'un problème sans perte d'information :
 - Sélection de variable pertinentes et non redondantes
 - Combinaison des variables initiales pour générer de nouvelles variables avec une dimensionalité différente mais avec un pouvoir discriminant plus important pour les données
-

Machines à vecteurs supports et méthodes à noyaux

- **Machines à vecteurs supports (SVM):**
 - Modèle de machine learning supervisé pour la régression ou la classification
 - Le principe est de chercher un hyperplan (une droite (1D) dans un plan (2D), un plan (2D) dans un cube/espace 3D, un hyperplan de dimension $n-1$ dans un hyperplan de dimension n) permettant de séparer au mieux les données
 - Les SVM cherchent à trouver l'hyperplan qui maximise la marge entre les points des différentes classes (l'hyperplan optimal pour la séparation et non seulement un hyperplan permettant de séparer les données)
 - Lorsque le problème n'est pas linéairement séparable (l'hyperplan qui sépare les données) n'existe pas dans l'espace de représentation des données, les SVM peuvent exploiter l'astuce du noyau
-

Machines à vecteurs supports et méthodes à noyaux

- **Méthode du noyau :**
 - La méthode du noyau consiste à projeter les données initialement représentées dans un espace dans lequel elles ne sont pas linéairement séparables, vers un nouvel espace de représentation de données (nouvelles variables descriptives générées) dans lequel les données seront linéairement séparables.
 - Exemples de noyaux très utilisés :
 - Noyau polynomial
 - Noyau gaussien
 - Noyau laplacien
-

Quantification vectorielle

- **Learning vector quantization (LVQ) :**
 - Le principe de la technique LVQ est que les données peuvent être compressées et synthétisées avec un minimum de perte d'information
 - Une des techniques LVQ par exemple en clustering est de remplacer les ensembles de données très proches par une donnée « virtuelle / moyenne » qui synthétise les caractéristiques du sous-ensemble de données.
 - Une telle approche nécessite donc de définir le nombre de « moyennes » à considérer mais également des contraintes sur les sous-ensembles constituant cette moyenne (taille minimale d'un sous-ensemble, densité minimale pour que l'agrégation donne un résultat cohérent, ...)
-


Réseaux de neurones et Deep Learning

- **Réseau de neurones :**
 - Un neurone biologique reçoit des signaux de la part d'autres neurones et les combine. Si le résultat est un signal assez fort alors le neurone s'active et émet à son tour des signaux à d'autres neurones.
 - Un neurone informatique reçoit les valeurs des variables descriptives d'une donnée. Il effectue une combinaison linéaire pondérée des entrées. Il applique une fonction d'activation pour évaluer la sortie. Ensuite il transmet cette sortie aux neurones de la couche suivante.
 - L'apprentissage d'un réseau de neurones consiste à modifier les différents poids associés aux entrées jusqu'à ce que le passage des données dans le réseau de neurones donne en sortie la valeur attendue.
-


Réseaux de neurones et Deep Learning

- Réseau de neurones :

Neurone informatique




Neurone biologique




Réseaux de neurones et Deep Learning

- Réseau de neurones :

Neurone informatique



Réseau de neurones




Réseaux de neurones et Deep Learning

- **Deep Learning :**
 - Le deep learning est une branche du machine learning qui consiste à empiler plusieurs couches de modèles d'inférences de façon à obtenir un meilleur résultat en sortie finale.
 - L'effet de cet empilement est comme l'astuce du noyau car si les couches exécutent des transformations linéaires ça permettra éventuellement de projeter les données dans un espace dans lequel elles sont linéairement séparables.
 - Le deep learning peut se faire avec différents modèles d'intelligence artificielle, mais le terme référence souvent l'apprentissage profond de réseaux de neurones
-

Réseaux de neurones et Deep Learning

$$z = b + \sum_j w_j x_j \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$



Rappel sur les fonctions approchées (développement limité)

Formule de Taylor
Développement limité d'ordre 1

$$\begin{aligned} f(x) &\approx f(a) + (x - a)f'(a) \\ \Delta f(x) &\approx \Delta x f'(a) \\ \frac{\Delta f(x)}{\Delta x} &\approx f'(a) \end{aligned}$$

Fonction à deux variables
Développement limité d'ordre 1


$$\begin{aligned} f(x, y) &\approx f(a, b) + (x - a) \frac{\partial f}{\partial x}(a, b) + (y - b) \frac{\partial f}{\partial y}(a, b) \\ \Delta f(x, y) &\approx \Delta x \frac{\partial f}{\partial x}(a, b) + \Delta y \frac{\partial f}{\partial y}(a, b) \end{aligned}$$

Réseaux de neurones et Deep Learning

$$z = b + \sum_j w_j x_j \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

Rappel sur les fonctions approchées (développement limité)

$$\Delta C(w, b) \approx (\Delta w, \Delta b) \cdot \nabla C$$



On part des poids et biais actuels : w_t, b_t

On obtient une sortie y_t

On compare la sortie y_t avec la sortie optimale/souhaitée y_o

On calcule un cout actuel C_t dépendant de l'erreur entre y_t et y_o


On cherche à varier les poids et les biais w_t, b_t légèrement pour obtenir un nouveau cout $C < C_t$: $(\Delta C < 0)$

Comment choisir $(\Delta w, \Delta b)$ de façon à être sûr que $\Delta C(w, b)$ est négatif => diminution du cout ?

$\Rightarrow$ On remarque que si on prend $(\Delta w, \Delta b) = -\eta \nabla C$ alors $\Delta C(w, b) \approx -\eta \nabla C^2 < 0$

Avec η un nombre positif (appelé learning rate)

Réseaux de neurones et Deep Learning



- Learning rate trop grand : risque de ne jamais tomber sur le minimum à cause des grands sauts de poids/biais
- Learning rate trop faible : risque de trouver le minimum après un très grand nombre d'itérations (apprentissage lent)
- Se baser uniquement sur le learning rate sans optimisation : risque de se retrouver bloqué dans un minimum local alors qu'un minimum global existe un peu plus loin

Réseaux de neurones et Deep Learning

- **Entraîner un réseau de neurones :**
 - Package utiles :
 - `import tensorflow as tf`
 - Module Tensorflow
 - `from tensorflow import keras`
 - Module Keras pour interagir avec Tensorflow en respectant l'API Keras
 - `from tensorflow.keras.models import Sequential`
 - Le modèle séquentiel est tel que la sortie d'une couche est l'entrée de la suivante
 - `from tensorflow.keras.layers import Dense`
 - La couche Dense est une couche complètement connectée de neurones
 - D'autres type de couches existent comme Conv2D, Dropout, Flatten, et MaxPooling2D

Réseaux de neurones et Deep Learning

- **Entraîner un réseau de neurones :**
 - Mise en œuvre :
 - `model = Sequential()`
 - Instancier un objet Sequential et le garder dans la variable nommée « model »
 - Cet objet sera utilisé pour définir la structure du réseau de neurones
 - `model.add(Dense(10))`
 - Instancier une couche Dense de 10 neurones
 - Passer la couche dense instanciée en argument à la fonction « add » qui ajoute une couche au réseau
 - `model.compile()`
 - L'étape de la compilation est celle qui permet de spécifier les métriques et les algorithmes utilisés
-

Réseaux de neurones et Deep Learning

- **Entraîner un réseau de neurones :**
 - Mise en œuvre :
 - `model.fit()`
 - La fonction `fit` est celle qui permet de réaliser l'apprentissage du modèle
 - `model.evaluate()`
 - La fonction « `evaluate` » est celle qui permet d'évaluer le modèle sur un jeu de test
 - `model.predict()`
 - La fonction `predict` est celle qui permet d'obtenir une prédiction pour une donnée via le modèle
-

Réseaux de neurones et Deep Learning

- **Paramètres du réseau de neurones :**
 - **Optimizer :**
 - L'apprentissage des réseaux de neurones est basé sur l'algorithme de la descente du gradient pour trouver l'optimum
 - Le paramètre « Optimizer » permet de spécifier l'algorithme utilisé pour optimiser la recherche de l'optimum.
 - « Adam » est l'optimiseur le plus utilisé en pratique qui a fait ses preuves dans plusieurs cas d'usage
 - **Loss :**
 - La fonction d'erreur à minimiser afin d'améliorer le modèle
-

Réseaux de neurones et Deep Learning

- **Paramètres du réseau de neurones :**
 - Accuracy :
 - La fonction « objectif » qui permet de confirmer l'impact de la minimisation de la fonction d'erreur
 - Learning rate :
 - Paramètre permettant de préciser à quel point les poids du réseaux de neurones doivent être modifiés pour optimiser le modèle
-

Réseaux de neurones et Deep Learning

- **Problèmes de disparition et d'explosion des gradients**
 - Disparition des gradients :
 - Les gradients deviennent trop petits de façon à ce que le modèle n'apprenne quasiment plus rien
 - Solutions possibles :
 - Utiliser fonction d'activation ReLU
 - Explosion des gradients :
 - Les gradients deviennent trop grands ce qui empêche la convergence
 - Solutions possibles :
 - Normalisation
 - Réduction du paramètre « learning-rate »
-

Réseaux de neurones et Deep Learning

- **Optimiseurs plus rapides**

- SGD (Stochastic Gradient Decent) :

- La méthode SGD est la plus simple pour modifier les paramètres du modèle en minimisant la fonction d'erreur.
 - La méthode SGD utilise un paramètre learning-rate fixe pour tous les paramètres du modèle.

- L'optimiseur MomentumOptimizer :

- Cet optimiseur ajout un terme “momentum” à la décente du gradient qui tient compte des gradients précédents
-

Réseaux de neurones et Deep Learning

- **Optimiseurs plus rapides :**
 - L'optimiseur gradient accéléré de Nesterov :
 - Cet optimiseur est une amélioration du « MomentumOptimizer » qui consiste à faire un pas dans le sens du « momentum » et le corriger en fonction du gradient courant au lieu de juste l'estimer.
 - L'optimiseur AdaGrad :
 - L'optimiseur AdaGrad (Adaptive Gradient) est une amélioration de la méthode SGD qui consiste à utiliser un paramètre learning-rate variable
 - Les paramètres modifiés le plus souvent se voient attribués un learning-rate plus faible.
 - Les paramètres modifiés le moins souvent se voient attribués un learning-rate plus grand.
-

Réseaux de neurones et Deep Learning

- **Optimiseurs plus rapides**

- L'optimiseur RMSProp (Root Mean Square Propagation) :
 - Après un certain nombre de batchs si le learning-rate devient trop faible l'apprentissage prend plus de temps
 - RMSProp essaye de corriger ce problème en utilisant une décroissance exponentielle du learning-rate
 - AdaGrad et RMSProp utilise un momentum pour éviter les minimums locaux
 - L'optimiseur Adam :
 - ADAGrad et RMSProp se base sur les anciens learning-rates pour estimer les nouveaux
 - Adam se base également sur les anciens gradients
-

Réseaux de neurones et Deep Learning

- **Éviter le sur-ajustement grâce à la régularisation :**
 - Le sur-ajustement (overfitting) est le fait que le modèle devient collé aux données d'apprentissage et perd son pouvoir de généralisation.
 - L'objectif de l'apprentissage n'est pas d'obtenir un modèle collé aux données d'apprentissage mais un modèle qu'on peut utiliser sur des données en dehors de ceux d'apprentissage.
 - Les valeurs extrêmes (outliers) sont des exceptions des données d'apprentissage qui peuvent engendrer un grand taux d'erreurs de prédiction à l'exploitation du modèle.
 - La régulation pénalise les valeurs extrêmes et permet ainsi de minimiser l'effet de sur-apprentissage sur la performance de prédiction.
-

Ensemble learning et arbres de décision


- **Ensemble learning:**
 - Une approche d'ensemble est une technique qui se base sur la combinaison d'un ensemble de modèles pour établir des prédictions dans l'objectif d'améliorer la performance en prédiction
 - Il existe trois types principaux d'approches d'ensembles qui peuvent elle-même être combinées:
 - **Bagging**
 - **Stacking**
 - **Boosting**
-

Ensemble learning et arbres de décision

- **L'apprentissage par des méthodes d'ensembles :**
 - Le Bagging :
 - Diviser aléatoirement l'ensemble d'apprentissage en plusieurs parties.
 - Un modèle est appris à partir de chaque partie.
 - Le résultat final est la combinaison des résultats de tous les modèles appris.
-

Ensemble learning et arbres de décision

- Le Bagging :




Ensemble learning et arbres de décision

- **L'apprentissage par des méthodes d'ensembles :**
 - Le Boosting :
 - La différence avec le bagging est que les sous-ensembles d'apprentissage ne sont pas choisis aléatoirement.
 - Le premier sous-ensemble est aléatoire et permet d'apprendre le premier modèle.
 - Les données d'apprentissage dont la prédiction n'est pas correcte se voient affectées une probabilité par rapport à l'erreur de prédiction.
 - L'idée est que les données avec une erreur de prédiction pour un modèle doivent avoir plus de probabilité de faire partie du sous-ensemble d'apprentissage du modèle suivant.
 - Le principe est que chaque modèle essaye de corriger les erreurs du précédent.
-

Ensemble learning et arbres de décision

■ Le Boosting :




Ensemble learning et arbres de décision

- **L'apprentissage par des méthodes d'ensembles :**
 - Le Stacking :
 - Diviser l'ensemble d'apprentissage en plusieurs parties
 - Construire autant de modèles que de parties.
 - Chaque modèle réalise l'apprentissage sur un ensemble de données
 - Les modèles appris constituent une première couche.
 - La deuxième couche des modèles est composée d'un seul modèle qui apprend à combiner les prédictions de la première couche pour établir une prédiction finale.
-

Ensemble learning et arbres de décision

- Le stacking :



Ensemble learning et arbres de décision

- **Arbre de décision :**

- Les arbres de décision sont les modèles les plus utilisés dans les approches d'ensemble pour les raisons suivantes :
 - Apprentissage rapide comparé à d'autres modèles comme les réseaux de neurones
 - Modèle auto-explicable et facile à interpréter
 - Techniques et méthode facile pour interpréter le résultat des différents arbres de décision constituant l'approche d'ensemble et sortir des résultats comme l'importance des variables descriptives
-

Les algorithmes de Bandits, optimisme face à l'incertitude

- Les algorithmes de bandits font partie de la classe des méthodes d'apprentissage par renforcement.
 - L'objectif dans cet apprentissage est d'apprendre une stratégie permettant de maximiser le gain / la récompense
 - L'apprentissage est réalisé en essayant d'osciller efficacement entre :
 - L'exploitation des expériences précédentes pour lesquelles on est optimistes et on s'attend à des bonnes récompenses.
 - L'exploration de nouvelles expériences incertaines à la recherche de meilleures récompenses mais avec le risque de pénalités.
-

Principes d'inférence et d'apprentissage bayésiens.

- L'apprentissage bayésien traite les paramètres du modèle comme des variables aléatoires
 - l'estimation des paramètres revient à calculer les distributions postérieures de ces variables aléatoires en fonction des données observées.
 - L'inférence bayésienne est basée sur le théorème de Bays qui pour des évènements A et B , permet de déterminer la probabilité de A sachant B en fonction des probabilités suivantes (à condition que la probabilité de B ne soit pas égale à 0) :
 - La probabilité de A
 - La probabilité de B
 - La probabilité de B sachant A ,
-

Modèles graphiques : réseaux bayésiens, champs de Markov, inférence et apprentissage

- Un réseau bayésien est un modèle graphique probabiliste dans lequel :
 - les nœuds représentent des variables aléatoires
 - la distribution de probabilité jointe de toutes ces variables s'exprime comme le produit des distributions de chaque nœud/variable conditionnellement à ses parents.
 - Représentation asymétrique des dépendances
 - Modélise bien les relations causales (diagnostic)
 - Un champ de Markov est un modèle graphique dans lequel un ensemble de variables aléatoires vérifie une propriété de Markov relativement à un graphe non orienté.
 - Représentation symétrique des dépendances
 - Souvent utilisées pour modéliser les dépendances spatiales (analyse d'image)
-

Méthodes bayésiennes : Naive Bayes, mélanges de gaussiennes, processus gaussiens.

- Naive Bayes:
 - Un modèle de classification bayésienne probabiliste basé sur le théorème de Bayes avec une hypothèse sur l'indépendance des variables (hypothèse naive car pas toujours vérifiée)
 - Mélange de gaussiennes:
 - un modèle statistique permettant d'estimer de façon paramétrique la distribution de variables aléatoires en les modélisant comme somme de plusieurs gaussiennes
 - Processus gaussiens:
 - Les variables aléatoires suivent une loi normale et toute combinaison linéaire est normalement distribuée.
-

Modèles markoviens : processus markoviens, chaînes de Markov, chaînes de Markov cachées, filtrage bayésien

- Processus de Markov :
 - probabilité d'une variable aléatoire possédant la propriété de markov (la distribution conditionnelle de probabilité des états futurs ne dépend que de l'état présent et non pas des états passés)
- Chaîne de Markov :
 - les transitions prises sont inconnues de l'utilisateur mais les états d'une exécution sont connus
- Chaîne de Markov cachée :
 - chaîne de Markov à paramètres inconnu contrairement à une chaîne de Markov classique
- Filtrage bayésien :
 - un algorithme très utilisé en informatique / robotique pour calculer la probabilité de plusieurs croyances afin de déduire par exemple la position et l'orientation d'un robot

Les spécificités liées au développement d'un modèle en environnement distribué

- Un modèle en mode centralisé accède à l'ensemble des données et exécute les différentes étapes d'apprentissage en ayant la visibilité sur l'ensemble des données
 - Un modèle en mode distribué peut fonctionner principalement de deux façons :
 - Chaque agent n'aura la visibilité que sur une partie de données, et son apprentissage ne tiendra pas compte de l'ensemble des données ni de ce que les autres agents ont accumulé comme connaissance par leur apprentissage
 - Cette approche nécessite de mettre en place des techniques d'agrégation pour combiner ce que chaque agent a pu apprendre dans son environnement
 - Chaque agent synchronise sa connaissance avec les autres agents de l'environnement distribué
 - Cette approche ralentit la phase d'apprentissage et réduit l'intérêt de la distribution
-

Le déploiement Big Data avec Spark et la MLlib

- L'outil spark est le composant big data de référence en matière de traitement de données en mode distribué
 - Spark offre plusieurs fonctionnalités pour traiter les données notamment la partie machine learning avec les bibliothèques Mlib ou SparkML
 - Les modèles développés sous spark peuvent être exportés sous forme de pipelines
 - Les pipelines peuvent être chargés et exploités pour traiter des données et obtenir les prédictions du modèle
-

Le Cloud : Amazon, Microsoft Azure ML, IBM Bluemix...

- Les grands fournisseurs des services cloud proposent souvent des fonctionnalités pour faciliter la mise en place des modèles machine learning et leur déploiement notamment avec :
 - Des pipelines CI / CD
 - Des environnement intégrés (Machine learning Studio)
 - La possibilité d'exploiter des modèles pré-entraînés et performants
 - La possibilité de faire du low-code ou du no-code pour la mise en place des flux machine learning
 - Les outils permettant d'évaluer rapidement et de tester les modèles
 - Les outils facilitant le travail collaboratif sur des projets machine learning
-

La maintenance du modèle

- Un modèle en production est un modèle qui vit et doit être maintenu
 - Des mécanismes de contrôle de données doivent être mis en place
 - Détecter les changements dans les distributions des données qui rendront le modèle inefficace
 - Mettre en place un flux de traitement permettant de ré-entraîner le modèle en cas de concept-drift
 - L'usage des outils spécifique pour le contrôle des versions des modèles, de leurs paramètres, et de leur performance est recommandée pour faciliter la maintenance et la gestion des modèles en production.
-


Machine Learning en production

L'environnement docker

- **Docker** est une solution logicielle qui permet d'exécuter du code (y compris des logiciels système) en local sur sa machine mais dans un environnement isolé (appelé « container »).
- **Docker** est une alternative aux machines virtuelles.
- **Docker** est utilisé comme alternative car ils sont plus légers en termes de ressources que les **machines virtuelles**.
- **Docker** est l'une des technologies de référence en matière d'industrialisation d'application et de modèles

Isolation lourde

Salut! nous sommes deux Machines Virtuels, Chacun de nous exécute non seulement une copie complète d'OS, mais une copie virtuelle de tout le matériel dont le OS a besoin pour fonctionner.



Isolation légère

Salut! nous sommes deux conteneurs, nous sommes isolés mais nous partageons le système d'exploitation (OS).

